

المحاضرة 3+ مشروع عملي AEC

مادة الكهرصوت

قسم الإلكترونيات والاتصالات 2025
السنة 4

م. أروى نصري

مستوى الشدة (اعتبارات تصميم) :

في مثال سابق وجدنا أنه عندما تتضاعف الشدة الصوتية بين مستمع وآخر فإن التفاوت في مستوى الشدة بينهما يكون 3dB وهو مقبول في قاعات الاستماع (يجب ألا تتفاوت مستوى الشدة بما يتجاوز 4-10dB)

(ليبدو الصوت بنفس الجهارة تقريباً راجع فكرة الفون من منحنيات الجهارة)

يجب أن يصل للمستمع مستوى أدنى للصوت (صوت ناتج عن مجهر مثلاً) يزيد 25dB عن مستوى الضجيج الوسطي في المكان (مثال ضجيج ناتج عن نظام تكييف في القاعة)

(ليبدو بجهارة أعلى وضوحاً)

في قاعة استماع وبحال مستمع يتلقى الإشارة الصوتية (نفسها) من أكثر من مجهر (نهتم بأقرب مجهرين) فإن التفاوت بين مستويي الشدة الناتج عنهما عند المستمع لا يتجاوز 3-4dB حتى لا يكون ملحوظاً ولا ينبغي للتأخير

بين وصول إشارتي المجهرين أن يتجاوز فاصل Δt يتعلق بالثابت الزمني 0.1sec

الأوكتاف: Octave:

الأوكتاف هو علاقة رياضية بين ترددين، حيث يكون أحد الترددين ضعف الآخر.

• تقسيم الأوكتافات:

كل أوكتاف يُضاعف التردد السابق (مثال: الأوكتاف 5 = 320-640Hz، والأوكتاف 6 = 640-1,280Hz).

عند تصميم المكبرات نقسم المدى

الترددى لاوكتافات

باص

متوسط

تريبل

جدول الأوكتافات العشر في السمع البشري

الأوكتاف	النطاق الترددي (هرتز)	الأمثلة الشائعة	ملاحظات
1	20 – 40	زئير الأسود، رعد بعيد	تُسمعه الأذن البشرية (شعور أكثر من سماع)
2	40 – 80	طبول عميقة، باصات الموسيقى	يُحسن به في الجسد أكثر من الأذن.
3	80 – 160	جيتار الباص، صوت مروحية	أساسيات الإيقاع في الموسيقى.
4	160 – 320	صوت رجل غليظ، بيانو منخفض	نطاق الكلام الذكري العميق.
5	320 – 640	صوت امرأة، كمان منخفض	نطاق الكلام الأنثوي الأساسي.
6	640 – 1,280	كلام واضح، جيتار أكوستيك	أهم نطاق لفهم الكلام.
7	1,280 – 2,560	أصوات الأطفال، بيانو عالي	نطاق الحروف الساكنة (مثل "س"، "ت")
8	2,560 – 5,120	صفارة الإنذار، أصوات طيور	حساسية الأذن القصوى هنا.
9	5,120 – 10,240	زقزقة عصافير، أصوات معدنية	يُفقد مع التقدم في العمر.
10	10,240 – 20,000	صفارات حادة، ترددات إلكترونية	مسموع لمعظم البالغين فوق 40 سنة

يرتبط بإدراك الأذن البشرية، حيث تسمع نغمتين بفارق أوكتاف كأنهما **نفس** النغمة لكن
بطبقة مختلفة

مثال:

الانتقال من 440Hz إلى 880Hz (أوكتاف واحد أعلى)

440 هرتز (نغمة "لا" الموسيقية) نغمة $A4 = 440\text{Hz}$ ، ونغمة $A5 = 880\text{Hz}$ الفرق

بينهما أوكتاف واحد. رغم أن التردد تضاعف، الأذن تسمع النغمتين كأنهما متشابهتان لكن إحداهما
أعلى.

ظاهرة التقنيع : Masking effect

• ظاهرة تحدث عندما يُخفي صوتٌ قوي (أو ذو تردد معين) صوتًا آخر أضعف (أو بتردد قريب)، مما يجعل الأذن غير قادرة على سماع الصوت الخفي بوضوح.

• كيف تحدث هذه الظاهرة؟

1. التداخل الترددي (Frequency Masking):

إذا وُجد صوتان بترددات متقاربة (مثل 1000 هرتز و 1050 هرتز)، الصوت الأقوى سيُخفي الأضعف. مثال: في حفلة موسيقية، صوت الجيتار الكهربائي (القوي) قد يُخفي صوت الكمان (الضعيف) إذا كانا يعزفان نغمات متشابهة.


2. التداخل الزمني (Temporal Masking):

صوت قوي مفاجئ (مثل تصفيق) قد يُخفي أصوات تليه بفترة قصيرة. مثال: عند سماع دوي انفجار، قد لا تسمع الأصوات الخافتة التي تليه مباشرة.

3. التداخل في مستوى الشدة (Amplitude Masking):

الأصوات العالية جدًا تُخفي كل الأصوات الأقل شدة، حتى لو كانت بترددات مختلفة. مثال: إقلاع طائرة قد يُخفي حتى أصوات الأشخاص المتحدثين بجانبك.

- السبب هو حدود الأذن البشرية: لا تستطيع تمييز الأصوات القريبة في التردد أو الزمن إذا كان هناك فرق كبير في الشدة



• تطبيقات عملية في الحياة والهندسة الصوتية

• 1. في ضغط الملفات الصوتية MP3 Compression

تُحذف الأصوات التي يتم إخفاؤها تلقائيًا بواسطة أصوات أخرى (لأن الأذن لن تسمعها أساسًا)، مما يقلل حجم الملف دون فقدان ملحوظ في الجودة.

• 2. في تصميم السماعات والموسيقى

عند **Mixing** أغنية، يُقلل مهندسو الصوت من ترددات بعض الآلات التي قد تُخفي غيرها (مثل خفض الباص عند وجود غناء رئيسي).

• 3. في أنظمة الاتصالات

تُصمم أنظمة كبح الضوضاء (Noise Cancellation) باستغلال هذه الظاهرة لإخفاء الأصوات غير المرغوب فيها.

ظاهرة الصدى : Echo

- الصدى هو ظاهرة انعكاس الصوت عن سطح عاكس (مثل جبل، جدار) بحيث يصل إلى الأذن بعد سماع الصوت الأصلي بفارق زمني أكبر من 0.1 ثانية .

$$\text{velocity} = \frac{\text{Distance travelled}}{\text{time taken}} = \frac{2d}{t}$$

- زمن الصدى ليُشعر به المتكلم :

$$2d = 344 \times 0.1 = 34.4 \text{ m}$$

$$d = 17.2 \text{ m}$$

لكي يُسمع الصدى، يجب أن تكون :

1. المسافة بين المصدر والسطح العاكس $17\text{m} <$ (لأن الصوت يحتاج ~ 0.1 ثانية لقطع هذه المسافة ذهابًا وإيابًا)
2. زمن تأخير ملحوظ: إذا كان التأخير > 0.4 ثانية عمليا لانشعر بالصدى بل يندمج الصوت المنعكس مع الأصلي ويُسمى

ترداد Reverb

3. إذا كان التأخير بين الصوت الأصلي والصدى (المنعكس) < 0.5 ثانية، يبدأ المستمع بتمييز الصدى كصوت منفصل

الترداد : reverbation

الـ **Reverb** هو ظاهرة صوتية طبيعية أو إلكترونية تحدث استمرارية للصوت بعد انتهاء المصدر الأصلي، نتيجة انعكاس

الموجات الصوتية على الأسطح المحيطة (مثل الجدران، الأرضيات، الأسقف) وتندمج الموجات الصوتية المنعكسة فلا يميزها

المستمع كصدى و هي تقوي الصوت في القاعات وتكسبه وضوحا وتؤخذ بالاعتبار عند تصميم القاعات الصوتية

يحسب زمن التردد بالعلاقة :

$$RT60 = \frac{0.161 \times V}{A}$$


$$A = \sum (S \times \alpha)$$

وهو زمن نزول مستوى الشدة 60dB عن مستوى المصدر

A الامتصاص الصوتي الكلي للغرفة (بوحدة م² سايبين)

حيث أن نزول مستوى الشدة 60dB عند هذا الزمن يعني انخفاض الضغط الصوتي ألف مرة عن المصدر

$$20 \log (P_2/P_1) = 20 \log 1,000 = 60 \text{ dB.}$$




مثال:

- غرفة حجمها 100 م³، ومساحة أسطحها 150 م²، ومتوسط معامل الامتصاص للغرفة 0.2

$$A = 150 \times 0.2 = 30 \text{ م}^2 \text{ سابين}$$


$$RT60 = \frac{0.161 \times 100}{30} \approx 0.54 \text{ ثانية}$$



مشروع عملي - Mimi Project - Acoustic Echo Cancellation using Adaptive filters

إزالة أثر الصدى الناتج عن تعدد المسارات الصوتية في غرفة تسجيل باستخدام المرشحات المتكيفة

- الحالة المدروسة: نظام (مرشح+موديل الصدى) يعمل على حذف الضجيج من إشارة صوت



- الموديل هو مسار الصدى هو الغرفة التي تحوي إشارة صوت مرغوبة مركبة مع إشارة المجهاز بعد تعرضها لتعدد المسارات

• الموديل مع المرشح = النظام

المدرّوس):

المرشح دوره إزالة إشارة echo بفصلها عن

إشارة المايك المرغوبة وذلك عبر

دخل المرشح إشارة صوت ضجيجية هي إشارة

المجهر (تساق للدخل لتقدير الاستجابة النبضية


لنظام مجهول هو الغرفة فيها مركبة لإشارة

مرغوبة)

وخرجه الإشارة المتنبأ بها لمسار الصدى بحيث

يكون خرج النظام أقرب مايكون للإشارة

المرغوبة



1- المرشح ضمن النظام المجهول (الغرفة او مودل الصدى) يعمل System identification


• عمل المرشح التنبؤ بنظام يحوي إشارات مركبة لمسار الصدى لفصل إشارة مرغوبة عن الضجيج

• الهدف التعرف على استجابة النظام عبر ضبط أوزان المرشح في كل دورة تحديث للأوزان لتقدير استجابة نظام مجهول(مودل

المسارات الصوتية) وصولاً للتنبؤ الأمثل وانتاج الخرج متنبأ به أقرب مايكون لمسار الصدى وبالتالي نحصل على إشارة المايك

المرغوبة بأعلى دقة عبر طرح الخطأ النهائي بعد أن يصبح اصغر مايمكن عند انتهاء التحديث

خرج المرشح وهو إشارة المتنبأ بها
للمسار الصوتي بعد تقليص مركبة
التداخل الصدى في كل دورة تنبؤ
(دورات تحديث أوزان المرشح وفق
خوارزمية NLMS في مثالنا)



خرج النظام

التطبيق 1 : عملية إزالة أثر تعدد المسارات بهدف تصفية الإشارة بغرض نقلها و

تسجيلها اعتماداً منهجية المرشح المتكيف لعمل system identification

التطبيق 2: إضافة أثر تعدد المسارات عمداً لصوت مسجل جاف dry ليعطي أثر

الغرفة مما يضيف أثر الريفيرب وهو أحد أغراض التسجيل الصوتي الاحترافي في

الاستديوهات العملية معاكسة للتطبيق 1 وتدعى system application

يطلب فهم التطبيقين عبر تنفيذ الأكواد المعطاة

العملية هي تنبؤ prediction

- النظام المتنبأ به الموديل هو مسار الصدى ضمن الغرفة
- عملية التنبؤ بالموديل هو معرفة سلوك الغرفة (كنظام له تابع تحويل او استجابة نبضية) مع ترددات الإشارة ضمنها بالنظر للمسألة كنموذج تعلم آلي لبناء machine learning model مبني على التنبؤ المتعدد multiple linear regression

Traditional Programming



Machine Learning



التعلم الآلي بإشراف :

- نستخدم أشعة الميزات (features) وهي عدة خصائص تحكم المودل المراد التنبؤ به (عددتها يؤثر على دقة بناء المودل اختيارها f-selection يحتاج خبرة في المجال المدروس (domain-knowledge) نبني داتا بأسطر وأعمدة (الأعمدة هي الخصائص والاسطر هي عدد الإشارات) ولكل سطر خرج ثم نقسم الداتا بين تدريب واختبار لبناء المودل ثم اختباره
- مثال : (خارجي) التنبؤ بالانبعاث الناتج عن سيارة :

Predicting continuous values with multiple linear regression

$$Co2\ Em = \theta_0 + \theta_1 Engine\ size + \theta_2 Cylinders + \dots$$

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

$$\hat{y} = \theta^T X$$

$$\theta^T = [\theta_0, \theta_1, \theta_2, \dots] \quad X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \dots \end{bmatrix}$$

X: Independent variable

Y: Dependent variable

	ENGINE SIZE	CYLINDERS	FUEL CONSUMPTION_COMB	CO2 EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.8	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	?

تتمة المثال :

Using MSE to expose the errors in the model

معادلة المرشح
المتكيف نفسها في
مثال المشروع
معادلة التنبؤ لإيجاد
قيم أوزان المعادلة
او المرشح
للحصول على
أصغر خطأ

$$\hat{y} = \theta^T X$$

$$\hat{y}_i = 140$$

the predicted emission of x_i

$$y_i = 196$$

actual value of x_i

$$y_i - \hat{y}_i = 196 - 140 = 56 \quad \text{residual error}$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

	ENGINE SIZE	CYLINDERS	FUEL CONSUMPTION_COMB	CO2 EMISSIONS
0	2.0	4	9.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267

تؤول المسألة إلى إيجاد قيم متغيرات الخصائص θ (أو نسميها الأوزان w) وإيجاد برامترات المثالية للموديل التي تجعل خطأ التوقع أقل ما يمكن لذا يجب معرفة ماهي البارامترات (الأوزان للمرشح في مشروعنا) ثم إيجاد طريقة لجعلها مثلى

مهمة التوقع الخطي جعل قيمة MSE أقل ما يمكن عبر إيجاد قيم البارامترات للمتغيرات الغير مرتبطة

Making predictions with multiple linear regression

	ENGINE SIZE	CYLINDERS	FUEL CONSUMPTION_COMB	CO2 EMISSIONS
0	2.0	4	8.5	198
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	?

$$\hat{y} = \theta^T x$$

$$\theta^T = [125, 6.2, 14, \dots]$$

$$\hat{y} = 125 + 6.2x_1 + 14x_2 + \dots$$

$$Co2Em = 125 + 6.2EngSize + 14 Cylinders + \dots$$

$$Co2Em = 125 + 6.2 \times 2.4 + 14 \times 4 + \dots$$

$$Co2Em = 214.1$$

حساب دقة التنبؤ بالاعتماد على قيم كمتوسط مربع الخطأ:

Evaluation Metrics in Regression Models

Regression accuracy

	ENGINE SIZE	CYLINDERS	FUEL CONSUMPTION_COMB	CO2 EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	138
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.8	267
9	2.4	4	9.2	212

Actual values

y

- MAE ★
- MSE ★
- RMSE ★
- ...

$\hat{y}$

	Prediction
6	234
7	256
8	267
9	210

Predicted values

$$Error = \frac{(232 - 234) + (255 - 256) + \dots}{4}$$

$$Error = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

عودة لتطبيق مفهوم التنبؤ حسب المثال السابق على المرشح المتكيف:

معادلة التنبؤ للمرشح المتكيف :
هي معادلة مستخلصة من معالجة الإشارة العشوائية بين علاقة الترابط الذاتي للخرج مع الترابط المتعارض بين الدخل والخرج


مهمة المعادلة إيجاد الأوزان في كل لفة من لفات التنبؤ (تقدير الخرج) وتحديث تابع الاستجابة للمرشح في كل لفة وصولاً لخطأ أصغري

يتم الوصول للخطأ الأصغري

وتحديث قيمته بكل لفة

بخوارزمية LMS أصغر خطأ

واستخدام GD الانحدار التدريجي .



$$\hat{y}(m) = \sum_{k=0}^{P-1} w_k x(m-k)$$
$$= \mathbf{w}^T \mathbf{x}$$

لحساب معاملات المرشح نحتاج :

the **autocorrelation** matrix of the **input signal**

the **crosscorrelation** vector of the **input and the desired signals**.

The optimum **w** value is $\mathbf{w}_o = \mathbf{R}_{xx}^{-1} \mathbf{r}_{yx}$


لحساب الخطأ الاصغري بخوارزمية **LMS** نحسب متوسط طاقة الخطأ :

$$e(m) = \mathbf{y}(m) - \hat{\mathbf{y}}(m)$$

$$\mathcal{E}[e^2(m)] = \mathcal{E}[(\mathbf{y}(m) - \mathbf{w}^T \mathbf{x})^2] = r_{yy}(0) - 2\mathbf{w}^T \mathbf{r}_{yx} + \mathbf{w}^T \mathbf{R}_{xx} \mathbf{w}$$

وللوصول للنهاية الصغرى العظمى نعدم مشتق المعادلة (طريقة الانحدار التدريجي) بالنسبة للأوزان فنجد :

$$\frac{\partial}{\partial \mathbf{w}} \mathcal{E}[e^2(m)] = -2\mathbf{r}_{yx} + 2\mathbf{w}^T \mathbf{R}_{xx}$$



معادلة تحديث الأوزان للوصول لأصغر خطأ الذي يقابل قيمة استجابة مثالية :

معادلة GD لتحديث أوزان المرشح بحيث نقلل الخطأ

معدل التعلم (خطوة السير باتجاه أصغر خطأ)

$$w(m+1) = w(m) + \mu \left(-\frac{\partial e^2(m)}{\partial w(m)} \right)$$

مشتق دالة الكلفة ويساوي الدخل مضروباً بالخطأ

$$\begin{aligned} \frac{\partial e^2(m)}{\partial w(m)} &= \frac{\partial}{\partial w(m)} [y(m) - w^T(m)x(m)]^2 \\ &= -2x(m)[y(m) - w^T(m)x(m)]^2 \\ &= -2x(m)e(m) \end{aligned}$$

$$\begin{pmatrix} \text{update value} \\ \text{of tap - weight} \\ \text{vector} \end{pmatrix} = \begin{pmatrix} \text{old value} \\ \text{of tap - weight} \\ \text{vector} \end{pmatrix} + \begin{pmatrix} \text{learning -} \\ \text{rate} \\ \text{parameter} \end{pmatrix} \begin{pmatrix} \text{tap -} \\ \text{input} \\ \text{vector} \end{pmatrix} \begin{pmatrix} \text{error} \\ \text{signal} \end{pmatrix}$$


يتم حساب الانحدار التدريجي لتحديث أوزان المرشح أو النموذج (نموذج التنبؤ) واتخاذ خطوة باتجاه تقليل الخطأ عند كل لفة من لفات تحديث الأوزان (أو كل لفة من لفات التدريب للنموذج)


$$0 < \mu < \frac{2}{\lambda_{\max}}$$

- معدل التعلم يعطي فكرة عن حجم الخطوة و سرعة التكيف : نختار قيمته من أجل ضمان تقارب الخوارزمية نحو قيمة أصغر للخطأ

Larger values for step size

- Increases adaptation rate (faster adaptation)
- Increases residual mean-squared error





عمليا نقوم بتحديث معاملات المرشح بحجم خطوة $(0 < \mu < 2)$ وفق NLMS وهي معدلة عن LMS هذه

الخوارزمية تزيد من سرعة تقارب LMS عبر تضمين المعامل التقارب المتغير $\frac{\mu}{\mathbf{x}_k^T \mathbf{x}_k + E}$

وتكون معادلة تحديث الأوزان مشابهة للسابقة ولها الشكل :

$$\mathbf{w}_{i+1} = \mathbf{w}_i + \frac{\mu}{\|\mathbf{x}\|^2 + E} x_i e[i]$$

• اعتبارات عملية للمشروع :

الخوارزمية NLMS مناسبة في تطبيقات real-time لحذف الصدى ، العامل E يضمن تجنب أثر حجم الخطوة الكبير عندما تكون $X_k^T X_k$ يصبح صغيراً.

هناك مبادلة بين أمرين عند اختيار قيمة μ وهما سرعة تقارب الخوارزمية و ضبط التكيف misadjustment ان خواص الاستجابة النبضية التي تحدد ماهية النظام room من أجل الإشارة المباشرة يمكن قياسها بعدة طرق و بأمكنة محددة بتطبيق إشارة صوتية معروفة وتسجيل هذه الاستجابة و التي هي نفسها echo-path impulse response. نتائج هذا القياس مخزنة في الملف المساعد room الذي يحتوي 1024 عينة.

إن عرض المجال الذي تحتله إشارة الكلام يصل حتى 4.3KHz و يمكن الحصول على معظم خواص الإشارة عند 4KHz لذا نحتاج كحد أدنى إلى معدل اعتيان 8ksps

الملف المساعد css الذي يحوي 5600 عينة لإشارة كلام مصطنعة من سلسلة مكونة من 20 مقطع صوتي لتشكيل الإشارة Lspeaker و يتم التعرف على المسار الصوتي لهذه الإشارة ضمن الغرفة بواسطة مرشح متكيف بعدد معاملات 1024 وفق خوارزمية NLMS باستخدام الطريقة و العلاقات المشروحة

كلمات مفتاحية للبحث عن الأسس النظرية :

- Adaptive filtering theory
- Wiener filters
- Adaptive signal processing
- Noise reduction using adaptive filters
- Echo cancellation using adaptive filters
- Acoustic path prediction using adaptive filters
- System identification using adaptive filter
- Modeling acoustic echo path
- Prediction using Multiple linear regression Machine learning
- Machine learning: multiple regression for prediction

المطلوب :

- صياغة المشروع AEC (كتابة re-write) بطريقة علمية تتضمن توضيحا لـ :
- ملخص المشروع – حالة المدروسة – المشكلة – الحل – الطريقة المنهجية المتبعة والاساس النظري المستند إليه الحل – مخطط وظيفي لترتيب العمل أو تدفقي –الأدوات المستخدمة للتنفيذ من ملفات ومعنى كل منها – النتائج (إن وجدت) وتفسيرها– الخلاصة المستفادة .
- التسليم : نسخة الكترونية أو خطية أو مطبوعة بعدة صفحات لا تتجاوز 3 أقصى مدة 20\6\2026 مع امنياتي بالتوفيق
- الملفات المساعدة المعطاة مع المشروع هي أدوات للتنفيذ على ماتلاب (خيار مفضل) لتسهيل العمل مع الكود البرمجي والمطلوب ربط الافكار النظرية مع ملفات المشروع مع النتائج فهما وتطبيقاً وصياغة التقرير (ممكن لمن لايرغب بماتلاب استخدام لغة بايثون مع مكتبات التعلم الآلي)
- تنفيذ ملف electroacoustic_class المعطى ايضا لتطبيق فكرة إضافة أثر المسارات system app